

《大数据分析与计算》综合实战大作业任务书 (Project Rubric)

核心赛题：基于多模态大数据的商品购买转化预测与推荐系统实战

一、项目背景与评分权重

根据《大数据分析与计算》课程大纲规划，本次大作业考察模式包括期中里程碑、期末系统交付、Kaggle公开竞技与组内答辩。

本任务书覆盖大纲中占总成绩 **70%** 的实践板块，具体分值如下：

- 期中考核 (20%)**：期中 EDA 报告与特征初探。
- 期末报告 (20%)**：端到端模型代码体系、架构与可解释性分析。
- Kaggle 竞赛打榜 (15%)**：参加推荐系统召回测试，参与官方保留测试集排名。
- 答辩与贡献度 (15%)**：基于 Github 代码仓提交记录的项目答辩。

平台提示：本作业涉及数十 GB 多模态数据，建议利用 Kaggle 平台提供的云端 GPU/CPU Notebooks 额度完成。

二、第一阶段：期中考核任务 (Midterm Milestone, 占总评 20%)

节点目标：完成数据认知、数据清洗规则制定以及初期特征挖掘。

交付物形式：包含图表与执行结果的 Jupyter Notebook (EDA_Checkpoint.ipynb)。

1. 数据可视化探索与商业规律提取 (10分)

- 多维分布分析 (5分)**：利用 Pandas 与可视化库 (Seaborn/Plotly)，对用户画像与交易特征进行交叉分析（如季节性偏好、地域消费特征等）。
- 业务洞察 (5分)**：图表需附带业务解读 (Business Insight)。分析异常峰值，说明数据现象对预测模型的指导意义。

2. 数据清洗构建与 AI 辅助运用 (10分)

- **清洗与特征规划 (6分)**: 提出空值、长尾分布及非结构化属性字段（如商品文字描述）的预处理逻辑与代码实现方案。
- **AI 辅助记录 (4分)**: 在报告中记录小组使用大语言模型（如 ChatGPT / Claude / AI Agent）辅助撰写代码与联合查询（Join）的过程与协作效率。

三、 第二阶段：期末工程交付（Final Submission, 占总评 35%）

节点目标: 构建机器学习分析系统，涵盖特征工程、模型流水线及模型可解释性。

交付物形式: 完整的 Jupyter Notebook (Final_Project.ipynb) 源码与运行结果，符合 Kaggle 竞赛要求的 Submission.csv。

模块 A：期末流水线工程与验证报告（20%）

- **Pipeline 架构与数据防泄漏 (Data Leakage) 控制 (8分)**
在进行 K-Fold 切分前，需避免对全局数据进行处理（如全局 Target 目标编码或 Standard Scaler 归一化）。预处理转换器需封装在 Scikit-learn 的 Pipeline 和 ColumnTransformer 内部执行。若存在数据泄漏情形，将扣除相应分数。
- **5折交叉验证稳定性 (6分)**
使用 K-Fold 算法计算五次训练的均值 ROC AUC 指标与方差区间，以验证分类器的泛化稳定性（需设定 random_state=610 作为基准参数）。
- **可解释性模型剖析 (XAI) (6分)**
运用课程涉及的 **SHAP** 或 **LIME** 框架分析全局特征权重图，并随机抽取预测样本点绘制瀑布归因图，解释模型分类依据。

模块 B：高阶竞技模块（公开赛事打榜，15分）

本模块提供探索复杂算法架构与海量候选集处理的渠道。

挑战任务 (Challenge Track)

Kaggle 官方 H&M 竞赛保留了最后 7 天的隐藏测试集用于最终评估。在此任务中：

1. **特征融合探讨**: 鼓励引入大模型或预训练视觉模型提取原始 28GB 图像的表征特征，运用降维技术合入主干模型。

2. **两阶段架构拓展**：参考传统的推荐系统范式（召回-精排）。先通过规则过滤候选集，再利用构建的分类器筛选出预测概率最高的前 12 件商品（对应竞赛指标 MAP@12）。
3. **平台测评验证**：将排布好的预测结果提交至原版 Kaggle H&M 竞赛的 Late Submission 评测接口。

评估机制

- **模块0分基准指标**: $\text{MAP@12} = 0.018$
- **模块满分达标指标**: $\text{MAP@12} = 0.033$
- **计分方式**：将 MAP@12 Private Score 和 Public Score 取平均值计算。指标值在 0.018 的基础上每增加 0.001 加 1 分，达到 0.033 及以上得满分（15分）。
- **证明材料**：交付物需包含带有系统时间戳的 Kaggle 成绩客观截图，必要时提交 Submission.csv 进行验证。

四、 第三阶段：个人贡献与期末线下答辩（Final Defense, 占总评 15%）

进行小组现场 10-15 分钟的项目展示。

- **代码贡献度考察**：结合 Github 提交记录与组内互评表，针对个人承担部分的逻辑进行考察与提问。
- **故障与反思诊断 (Failure Analysis)**：包含对系统构建过程中的故障分析，总结特征或模型未达预期的原因与调试过程。